



# INT104W12\_往年试卷解析v0.1

## 大题部分

### 混淆矩阵

(i.e. “prediction=No” means the account has less than \$1000):

- (1) In reality, there are a total of  $\frac{5+125=130}{[a]}$  accounts with a balance more than \$1000 and  $\frac{60+10=70}{[b]}$  accounts with a balance less than \$1000.
- (2) The overall accuracy is  $\frac{60+125}{[c]}$  and the recall is  $\frac{125}{[d]}$ .

n=200	Prediction=No	Prediction=Yes
Actual=No	60	10
Actual=Yes	5	125

(8 Marks)

横着看是事实上的真/假例（即真实的各个类别）；竖着看是预测得的正/负例（即预测得出的各个类别）。

- Precision: 真例中的正例/所有正例。

$$\text{查准率 } Precision = \frac{\sum_1^n TP_n}{\sum_1^n (TP_n + FP_n)}$$

- Recall: 真例中的正例/所有真例。

$$\text{查全率 } Recall = \frac{\sum_1^n TP_n}{\sum_1^n (TP_n + FN_n)}$$

- Accuracy: 模型正确分类的样本/总例。

$$\text{准确率 } Accuracy = \frac{\sum_1^n (TP_n + TN_n)}{\sum_1^n (TP_n + FP_n + FN_n + TN_n)}$$

$$\text{accuracy} = 60 + 125 / 60 + 10 + 5 + 125 = 0.925$$

$$\text{recall} = 125 / 125 + 5 = 0.962$$

## Python看api填空代码

```
numpy.random.randint(low, high=None, size=None, dtype=int)
```

- size: Output shape
- dtype: Desired dtype of the result

```
import numpy as np
number = np.random.randint(1, 100[e], size=(100[f]))
```

size类型: `size=(100,2)`代表结果的大小是100行2列, `size=100`代表大小是一个有100个元素的数组。

整除 `print(10//3)` = 3

取余 `print(10%3)` = 1

## 朴素贝叶斯计算后验概率

Outlook	Humidity	Wind Speed	Preference
Rainy	80%	0.5m/s	Yes
Rainy	40%	0.2m/s	Yes
Rainy	50%	5.0m/s	No
Rainy	50%	0.2m/s	Yes
Rainy	75%	4.0m/s	No
Sunny	70%	5.0m/s	No
Sunny	75%	0.4m/s	No
Sunny	80%	0.1m/s	No
Sunny	50%	0.2m/s	Yes
Sunny	40%	4.0m/s	Yes

请计算在Outlook=Rainy, Humidity<65%的情况下玩家的表现。

$$P(Yes|Rainy, Humidity < 65\%) = \frac{P(Rainy, Humidity < 65\%|Yes)P(Yes)}{P(Rainy, Humidity < 65\%)} \quad (1)$$

$$= \frac{P(Rainy|Yes)P(Humidity < 65\%|Yes)P(Yes)}{P(Rainy, Humidity < 65\%)} \quad (2)$$

$$= \frac{3/5 * 4/5 * 5/10}{3/10} \quad (3)$$

$$= 80\% \quad (4)$$

## ■ kNN用K近邻算法归类偏好

湿度65%，风速3m/s，晴天。

是否需要计算晴天阴天等非数值距离？

城市（曼哈顿）距离：

然后你会发现在计算距离前需要zscore标准化，否则由于数据规模不同，湿度的影响太小。

## ■ 计算交叉验证的准确度

## ■ k-means聚类迭代