

11 PCA

PCA基本定义与概念

特征值和特征向量是线性代数中的核心概念，对于理解 PCA 至关重要。

- 定义 (Definition)

如果 v 是一个非零向量，且 λ 是一个数，它们满足以下关系式：

$$Av = \lambda v$$

那么， v 就被称为矩阵 A 的一个**特征向量 (eigenvector)**，而 λ 则被称为对应的**特征值 (eigenvalue)**。

- **直观理解**：当矩阵 A 乘以特征向量 v 时，结果向量 Av 只是 v 的一个缩放（伸长或缩短），方向保持不变（除非 $\lambda \leq 0$ ），缩放的因子就是特征值 λ 。

- 特征值的数量

对于一个 $m \times m$ 的方阵 S ，特征值 λ 的求解基于以下方程：

$$Sv = \lambda v \iff (S - \lambda I)v = 0$$

要使这个方程有非零解 v ，矩阵 $(S - \lambda I)$ 必须是奇异的，即它的行列式必须为零：

$$|S - \lambda I| = 0$$

对于一个 $m \times m$ 矩阵，通过求解这个 m 阶多项式，最多可以得到 m 个不同的特征值。

案例一

- **矩阵 A** : $A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$
- **向量 v** : $v = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$
- **乘积 Av** : $\begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \times \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \times 1 + 1 \times 1 \\ 1 \times 1 + 2 \times 1 \end{bmatrix} = \begin{bmatrix} 3 \\ 3 \end{bmatrix}$

我们发现结果 $\begin{bmatrix} 3 \\ 3 \end{bmatrix}$ 可以写成原始向量 $\begin{bmatrix} 1 \\ 1 \end{bmatrix}$ 的 3 倍：

$$\begin{pmatrix} 3 \\ 3 \end{pmatrix} = 3 \times \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

结论：

- **特征向量 v** : $\begin{bmatrix} 1 \\ 1 \end{bmatrix}$
- **特征值 λ** : 3

求解特征值

求解特征值 λ

1. 计算特征方程 $|S - \lambda I| = 0$ 。

$$|S - \lambda I| = \begin{vmatrix} 2 - \lambda & 1 \\ 1 & 2 - \lambda \end{vmatrix} = (2 - \lambda)^2 - 1 = 0$$

2. 解方程得到两个特征值：

- $\lambda_1 = 1$
- $\lambda_2 = 3$

求解特征向量

将每个特征值代入 $(S - \lambda I)v = 0$ 中，求解对应的特征向量：

1. 对于 $\lambda_1 = 1$ ：

$$(S - 1I)v_1 = \begin{bmatrix} 2-1 & 1 \\ 1 & 2-1 \end{bmatrix} v_1 = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

解得 $x + y = 0$ ，即 $y = -x$ 。选择一个简单的非零解 $x = 1, y = -1$ 。

◦ 特征向量 v_1 ： $\begin{bmatrix} 1 \\ -1 \end{bmatrix}$

2. 对于 $\lambda_2 = 3$ ：

$$(S - 3I)v_2 = \begin{bmatrix} 2-3 & 1 \\ 1 & 2-3 \end{bmatrix} v_2 = \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

解得 $-x + y = 0$ ，即 $y = x$ 。选择一个简单的非零解 $x = 1, y = 1$ 。

◦ 特征向量 v_2 ： $\begin{bmatrix} 1 \\ 1 \end{bmatrix}$

对称矩阵的特性


在 PCA 中，我们通常处理协方差矩阵，它是一个对称矩阵，因此其特征值和特征向量具有一些特殊且重要的性质。

- **正交性 (Orthogonality)**：对于对称矩阵 S ，对应于不同特征值 ($\lambda_1 \neq \lambda_2$) 的特征向量是正交的。
 - 数学表达：若 $Sv_1 = \lambda_1 v_1$ 和 $Sv_2 = \lambda_2 v_2$ 且 $\lambda_1 \neq \lambda_2$ ，则 $v_1 \bullet v_2 = 0$ 。
- **实数特征值 (Real Eigenvalues)**：一个实数对称矩阵的所有特征值都是实数。
- **非负特征值 (Non-negative Eigenvalues)**：一个半正定矩阵 (positive semidefinite matrix) 的所有特征值都是非负的。
 - 半正定矩阵的定义是：对于任何向量 $w \in \mathbb{R}^n$ ，都有 $w^T S w \geq 0$ 。若 S 是半正定的，则其特征值 $\lambda \geq 0$ 。

特征分解的几何意义

这两页通过图示展示了矩阵 S 乘以向量 d 的几何过程，特别是当 S 是对称矩阵时 ($S = S^T$)。

1. **投影 (Projection)**：向量 d 可以分解为沿着特征向量 v_1 和 v_2 方向的分量 d_1 和 d_2 。
2. **缩放 (Scaling)**：当 S 作用于 d 时，其效果相当于将 d 投影到每个特征向量上，然后用对应的特征值 λ_i 来缩放这些分量。
 - 在图中，分量 d_1 被 λ_1 缩放成 $\lambda_1 d_1$ ，分量 d_2 被 λ_2 缩放成 $\lambda_2 d_2$ 。
3. **向量加法 (Vector Addition)**：缩放后的分量相加（向量加法）就得到了变换后的向量 $\tilde{d}$ 。
 - $Sd = \tilde{d}$
 - 如果 v_1, v_2 是标准化的特征向量，那么 $d = d_1 v_1 + d_2 v_2$ ，且 $\tilde{d} = Sd = S(d_1 v_1 + d_2 v_2) = d_1 (Sv_1) + d_2 (Sv_2) = d_1 (\lambda_1 v_1) + d_2 (\lambda_2 v_2)$ 。



求解特征值与特征向量的示例

这一页通过一个具体的 2×2 对称矩阵的例子，展示了求解特征值和特征向量的过程。

- 矩阵 S :

$$S = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$$

这是一个实数对称矩阵。

- 求解特征值 λ :

计算 $|S - \lambda I| = 0$:

$$S - \lambda I = \begin{bmatrix} 2 - \lambda & 1 \\ 1 & 2 - \lambda \end{bmatrix}$$

$$(2 - \lambda)^2 - 1 = 0$$

解得特征值 λ 为 **1** 和 **3**。

- 求解特征向量 v :

将特征值 $\lambda = 1$ 和 $\lambda = 3$ 分别代入 $(S - \lambda I)v = 0$ 中求解对应的特征向量。

- 最终得到的特征向量是: $\begin{pmatrix} 1 \\ -1 \end{pmatrix}$ 和 $\begin{pmatrix} 1 \\ 1 \end{pmatrix}$ 。
- 这两个特征向量是正交的，符合对称矩阵的性质。

对角分解 Diagonal Decomposition

对角分解，也称为**特征分解 (Eigen-decomposition)** 或**矩阵对角化定理 (Matrix Diagonalization Theorem)**，是一种将方阵分解为特征向量矩阵、特征值对角矩阵和特征向量矩阵的逆矩阵相乘形式的方法。

对角分解定理

- 定理内容

如果一个 $m \times m$ 的方阵 S 拥有 m 个线性无关的特征向量，那么它存在一个特征分解，形式如下：

$$S = U\Lambda U^{-1}$$

其中：

- U ：是由矩阵 S 的所有特征向量作为列向量组成的矩阵。
- Λ (**Lambda**)：是一个**对角矩阵**。其对角线上的元素是矩阵 S 对应的特征值 $\lambda_1, \lambda_2, \dots, \lambda_m$ 。通常按降序排列，即 $\lambda_i \geq \lambda_{i+1}$
- U^{-1} ：是矩阵 U 的逆矩阵。

- 唯一性

如果 S 的所有特征值都是不同的，那么这个特征分解是唯一的。

定理推导

推导过程证明了 $S = U\Lambda U^{-1}$ 这一分解形式是正确的：

1. 将 U 写成特征向量的组合：

$$U = [v_1, v_2, \dots, v_m]$$

2. 计算 S 乘以 U ：

$$SU = S[v_1, v_2, \dots, v_m] = [Sv_1, Sv_2, \dots, Sv_m]$$

3. 利用特征向量的定义 $Sv_i = \lambda_i v_i$ 进行替换：

$$SU = [\lambda_1 v_1, \lambda_2 v_2, \dots, \lambda_m v_m]$$

4. 将右侧的矩阵用 U 和对角矩阵 Λ 相乘表示：

$$[\lambda_1 v_1, \lambda_2 v_2, \dots, \lambda_m v_m] = U\Lambda$$

因此，我们得到 $SU = U\Lambda$ 。

5. 在等式 $SU = U\Lambda$ 的左侧乘以 U^{-1} ，即可得到最终的分解形式：

$$U^{-1}(SU) = U^{-1}(U\Lambda) \implies S = U\Lambda U^{-1}$$

实例演算与对称分解

第 10 页使用了矩阵 $S = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$ 进行实际计算：

- **特征值：** $\lambda_1 = 1, \lambda_2 = 3$ 。
- **特征向量：** $v_1 = \begin{pmatrix} 1 \\ -1 \end{pmatrix}, v_2 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ 。
- 构成 U 和 U^{-1} ：

$$U = \begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix}$$

$$U^{-1} = \begin{bmatrix} 1/2 & -1/2 \\ 1/2 & 1/2 \end{bmatrix}$$

- 分解结果：

$$S = U\Lambda U^{-1} = \begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 3 \end{bmatrix} \begin{bmatrix} 1/2 & -1/2 \\ 1/2 & 1/2 \end{bmatrix}$$

对称对角分解

由于原始矩阵 S 是对称矩阵，其特征向量是相互正交的。通过对特征向量进行归一化（将 U 中的每个向量除以其长度 $\sqrt{2}$ ），我们得到了一个特殊的特征向量矩阵 Q 。

- Q 矩阵：

$$Q = \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ -1/\sqrt{2} & 1/\sqrt{2} \end{bmatrix}$$

- Q 的性质： Q 是一个正交矩阵。正交矩阵有一个非常重要的特性：它的逆矩阵等于它的转置矩阵。

$$Q^{-1} = Q^T$$

- 最终分解形式：对于对称矩阵 S ，分解可以简化为：

$$S = Q\Lambda Q^T$$

这种形式被称为对称对角分解（或正交对角化），是 PCA 中分解协方差矩阵的基础。

这个过程说明，特征分解的本质就是将矩阵 S 映射到一个由其特征向量构成的坐标系中，在这个新坐标系下， S 的作用仅相当于一个对角矩阵 Λ 的缩放作用。

对称对角分解 Symmetric Diagonal Decomposition

专门针对对称矩阵的特征分解，这是 PCA 应用中的核心数学工具。定理内容：

- 前提条件：** 矩阵 S 是一个 $m \times m$ 的对称矩阵 ($S \in \mathbb{R}^{m \times m}$)。
- 结论：** 存在一个特征分解，其中特征向量矩阵 Q 是正交矩阵。
- 分解公式：

$$S = Q\Lambda Q^T$$

关键组成部分及特性：

1. Q 矩阵（特征向量矩阵）

- Q 的列是矩阵 S 的归一化特征向量（Normalized Eigenvectors）。这意味着每个特征向量的长度都为 1。
- Q 的列向量是相互正交的（Orthogonal）。这得益于对称矩阵的特性，即对应于不同特征值的特征向量相互正交。
- 正交矩阵的特性：** 由于 Q 是一个正交矩阵，它的逆矩阵等于它的转置矩阵。

$$Q^{-1} = Q^T$$

正是这一特性，使得对称矩阵的分解公式从 $S = U\Lambda U^{-1}$ 简化为 $S = Q\Lambda Q^T$ 。

2. Λ 矩阵（特征值矩阵）

- Λ 仍然是对角矩阵，对角线元素是特征值 λ_i 。
- 由于 S 是一个实数对称矩阵，所有的特征值和特征向量都是实数。

对称对角分解的重要性在于：

- 简化计算：** $Q^{-1} = Q^T$ 极大地简化了矩阵求逆的计算，这在处理大规模数据时非常重要。
- PCA 基础：** 在 PCA 中，我们通常对数据的协方差矩阵（Covariance Matrix）进行操作，而协方差矩阵是一个

标准的实数对称矩阵。因此，可以使用 $S = Q\Lambda Q^T$ 对其进行分解。这个分解的结果 Q （主成分方向）和 Λ （方差大小）正是 PCA 所需的。

对称对角分解案例讲解

将以一个 2×2 的实数对称矩阵 S 为例，进行分解。

原始对称矩阵 S

我们使用演示文稿中提供的对称矩阵 1：

$$S = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$$

求解特征值 Λ (Eigenvalues)

我们首先求解矩阵 S 的特征值 λ ，通过计算特征方程 $|S - \lambda I| = 0$ ：

$$(2 - \lambda)^2 - 1 = 0$$

解得两个特征值：

$$\lambda_1 = 1$$

$$\lambda_2 = 3$$

构造特征值对角矩阵 Λ （通常按降序排列，但在这里我们使用文档中的顺序 $\lambda_1 = 1, \lambda_2 = 3$ ）：

$$\Lambda = \begin{bmatrix} 1 & 0 \\ 0 & 3 \end{bmatrix}$$

求解特征向量 v 并归一化 Q (Normalized Eigenvectors)

接下来，我们为每个特征值求解对应的特征向量 v ，并对其进行归一化，以得到正交矩阵 Q 的列向量。

- 对于 $\lambda_1 = 1$ ：

求解 $(S - 1I)v_1 = 0$ ，得到的特征向量是 $\begin{pmatrix} 1 \\ -1 \end{pmatrix}$ 。

其长度为 $\sqrt{1^2 + (-1)^2} = \sqrt{2}$ 。

归一化后的特征向量 $q_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix} = \begin{pmatrix} 1/\sqrt{2} \\ -1/\sqrt{2} \end{pmatrix}$ 。

- 对于 $\lambda_2 = 3$ ：

求解 $(S - 3I)v_2 = 0$ ，得到的特征向量是 $\begin{pmatrix} 1 \\ 1 \end{pmatrix}$ 。

其长度为 $\sqrt{1^2 + 1^2} = \sqrt{2}$ 。

归一化后的特征向量 $q_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}$ 。

- 构造正交矩阵 Q ：

将归一化后的特征向量作为列向量构成 Q 矩阵：

$$Q = [q_1 \quad q_2] = \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ -1/\sqrt{2} & 1/\sqrt{2} \end{bmatrix}$$

对称分解结果

矩阵 Q 是一个正交矩阵，因此它的逆矩阵 Q^{-1} 等于它的转置 Q^T 。

$$Q^T = \begin{bmatrix} 1/\sqrt{2} & -1/\sqrt{2} \\ 1/\sqrt{2} & 1/\sqrt{2} \end{bmatrix}$$

最终，对称对角分解的结果为 $S = Q\Lambda Q^T$ ：

$$S = Q\Lambda Q^T = \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ -1/\sqrt{2} & 1/\sqrt{2} \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 3 \end{bmatrix} \begin{bmatrix} 1/\sqrt{2} & -1/\sqrt{2} \\ 1/\sqrt{2} & 1/\sqrt{2} \end{bmatrix}$$

意义：

这个分解告诉我们，矩阵 S 的作用（拉伸、旋转等线性变换）可以用三个连续的变换来表示：

1. Q^T ：将原始向量投影到由特征向量 q_1, q_2 定义的新坐标系上（旋转）。
2. Λ ：在新坐标系下，沿着每个特征向量方向进行缩放（缩放因子为特征值 1 和 3）。
3. Q ：将缩放后的向量从新坐标系旋转回原始坐标系。

这个过程，特别是对协方差矩阵的分解，是 PCA 的核心。

奇异值分解 Singular Value Decomposition, SVD

奇异值分解是一种强大的矩阵分解技术，它不像特征分解那样仅限于方阵，而是可以应用于任何 $m \times n$ 的矩阵 A 。

SVD 的分解形式

对于一个 $m \times n$ 的矩阵 A （秩为 r ），SVD 的分解形式如下：

$$A = U\Sigma V^T$$

其中：

- **U 矩阵**：是一个 $m \times m$ 的正交矩阵。它的列（称为左奇异向量）是 AA^T 的正交特征向量。
- **Σ (Sigma) 矩阵**：是一个 $m \times n$ 的矩阵。它是一个**对角矩阵**，对角线元素是**奇异值**（Singular values） σ_i 。
 - $\Sigma = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_r)$ 。
 - 奇异值 σ_i 是非负实数。
- **V^T 矩阵**：是一个 $n \times n$ 的矩阵。 V 的列（称为右奇异向量）是 $A^T A$ 的正交特征向量。

奇异值与特征值的关系

奇异值 σ_i 与 AA^T 和 $A^T A$ 的特征值 λ_i 之间存在直接关系：

- 矩阵 AA^T 的特征值与 $A^T A$ 的特征值是相同的。
- 奇异值 σ_i 是这些特征值 λ_i 的平方根：

$$\sigma_i = \sqrt{\lambda_i}$$

SVD 维度图示

通过图示展示了 SVD 中三个矩阵的维度关系：

矩阵	维度	描述
A	$m \times n$	原始矩阵
U	$m \times m$	左奇异向量矩阵
Σ	$m \times n$	奇异值矩阵
V^T	$n \times n$	右奇异向量矩阵的转置

A 的分解是： $A = U\Sigma V^T$ 。

SVD 案例

第一个具体的 3×2 矩阵 A 的 SVD 示例：

- 原始矩阵 A ：

$$A = \begin{bmatrix} 1 & -1 \\ 0 & 1 \\ 1 & 0 \end{bmatrix}$$

这里 $m = 3, n = 2$ 。

- SVD 结果：

$$A = U\Sigma V^T$$
$$\begin{bmatrix} 0 & 2/\sqrt{6} & 1/\sqrt{3} & 1 & 0 \\ 1/\sqrt{2} & -1/\sqrt{6} & 1/\sqrt{3} & 0 & \sqrt{3} \\ 1/\sqrt{2} & 1/\sqrt{6} & -1/\sqrt{3} & 0 & 0 \end{bmatrix} \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ 1/\sqrt{2} & -1/\sqrt{2} \end{bmatrix}$$

注意： 这里的 Σ 矩阵是 3×2 的， 其对角线上的奇异值是 1 和 $\sqrt{3}$ 。

具体过程

给定矩阵 $A = \begin{bmatrix} 1 & -1 \\ 0 & 1 \\ 1 & 0 \end{bmatrix}$ 。

步骤 1: 计算 $A^T A$ 并求其特征分解 (得到 V 和 Σ)

V 矩阵 (右奇异向量) 是由 $A^T A$ 的特征向量构成的。

- 计算 $A^T A$ ：

$$A^T A = \begin{pmatrix} 1 & 0 & 1 \\ -1 & 1 & 0 \end{pmatrix} \begin{pmatrix} 1 & -1 \\ 0 & 1 \\ 1 & 0 \end{pmatrix} = \begin{pmatrix} 2 & -1 \\ -1 & 2 \end{pmatrix}$$

- 求 $A^T A$ 的特征值 λ ： 计算 $|A^T A - \lambda I| = 0$ 。

$$(2 - \lambda)^2 - (-1)^2 = 0 \implies (2 - \lambda)^2 = 1$$

$$\lambda_1 = 3, \quad \lambda_2 = 1$$

- 计算奇异值 σ (得到 Σ)： 奇异值是特征值的平方根。

$$\sigma_1 = \sqrt{\lambda_1} = \sqrt{3}$$

$$\sigma_2 = \sqrt{\lambda_2} = \sqrt{1} = 1$$

由于 A 是 3×2 矩阵, Σ 是 3×2 矩阵, 其奇异值位于对角线上:

$$\Sigma = \begin{pmatrix} \sigma_1 & 0 \\ 0 & \sigma_2 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} \sqrt{3} & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix}$$

这与案例结果中的 Σ 矩阵相符 2 (注意: 案例中 $\sqrt{3}$ 和 1 的位置可能交换, 取决于特征值排序, 但结构相同)。

4. 求 $A^T A$ 的特征向量 (得到 V):

◦ 对于 $\lambda_1 = 3$: 求 $(A^T A - 3I)v_1 = 0$ 。

$$\begin{pmatrix} -1 & -1 & -1 & -1 \end{pmatrix} v_1 = 0 \implies v_1 = (1/\sqrt{2} \ -1/\sqrt{2}) \text{ (归一化后)}$$

◦ 对于 $\lambda_2 = 1$: 求 $(A^T A - 1I)v_2 = 0$ 。

$$\begin{pmatrix} 1 & -1 & -1 & 1 \end{pmatrix} v_2 = 0 \implies v_2 = (1/\sqrt{2} \ 1/\sqrt{2}) \text{ (归一化后)}$$

V 矩阵由 v_1 和 v_2 组成, 因此:

$$V = \begin{pmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ -1/\sqrt{2} & 1/\sqrt{2} \end{pmatrix}$$

转置后得到 V^T :

$$V^T = \begin{pmatrix} 1/\sqrt{2} & -1/\sqrt{2} \\ 1/\sqrt{2} & 1/\sqrt{2} \end{pmatrix}$$

这与案例结果中的 V^T 矩阵相符。

步骤 2: 计算 AA^T 并求其特征分解 (得到 U)

U 矩阵 (左奇异向量) 是由 AA^T 的特征向量构成的。

1. 计算 AA^T :

$$AA^T = \begin{pmatrix} 1 & -1 \\ 0 & 1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 1 & 0 & 1 \\ -1 & 1 & 0 \end{pmatrix} = \begin{pmatrix} 2 & -1 & 1 \\ -1 & 1 & 0 \\ 1 & 0 & 1 \end{pmatrix}$$

2. 求 AA^T 的特征值 λ : 由于 AA^T 和 $A^T A$ 具有相同的非零特征值 5, 所以特征值是 3, 1, 以及额外的零特征值 (因为 3×3 矩阵的秩为 2)。

$$\lambda_1 = 3, \quad \lambda_2 = 1, \quad \lambda_3 = 0$$

3. 求 AA^T 的特征向量 (得到 U): 求解 $(AA^T - \lambda I)u_i = 0$ 并归一化, 将得到 u_1, u_2, u_3 。

◦ u_1 对应 $\lambda_1 = 3$ 。

◦ u_2 对应 $\lambda_2 = 1$ 。

◦ u_3 对应 $\lambda_3 = 0$ 。

将 u_1, u_2, u_3 作为列向量组合起来, 即可得到 U 矩阵, 即案例结果中 3×3 的 U 矩阵

SVD 在降维 (尤其在 PCA 中, 如果数据没有中心化或协方差矩阵太大) 和数据压缩等领域有广泛应用。

降维 (Dimensionality Reduction)

这一部分内容介绍了降维的目的、方法以及它与基 (Basis) 变换之间的关系。

降维的目的和方法

- **问题：** 处理高维数据时，可能面临计算复杂、存储需求高以及数据稀疏等问题。
- **目的：** 通过降低数据的维度来解决这些问题。
- **方法：** 将高维数据投影到一个较低维度的子空间上 1。这可以使用**线性**或**非线性变换**来实现。
 - **线性变换**（如 PCA）计算简单。
 - 表示形式： 原始高维向量 x (维度为 N) 被转换成较低维度的向量 y (维度为 K ，且 $K \ll N$)。

$$\begin{matrix} x_1 & & y_1 \\ x = \begin{bmatrix} x_2 \\ \vdots \\ x_N \end{bmatrix} & \longrightarrow & y = \begin{bmatrix} y_2 \\ \vdots \\ y_K \end{bmatrix} \quad (K \ll N) \end{matrix}$$

- **线性变换公式：** $Y = UX$ 。其中 X 是原始数据向量 ($d \times 1$)， U 是一个投影矩阵 ($k \times d$)， Y 是降维后的向量 ($k \times 1$)。 ($k \ll d$)

降维与基变换

降维本质是**找到一个低维子空间中的基**，并将原始向量近似地表示在这个新基上。

- 原始空间表示 (Original space representation):
原始向量 $\underline{x}$ 可以通过一组 N 维基向量 $v_1, v_2, \dots, v_N$ 的线性组合来表示。

$$\underline{x} = a_1 v_1 + a_2 v_2 + \dots + a_N v_N$$

其系数表示为： $\begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_N \end{bmatrix}$ 。

- 低维子空间表示 (Lower-dimensional sub-space representation):
降维后的近似向量 $\hat{x}$ 只使用一组 K 维基向量 $u_1, u_2, \dots, u_K$ （其中 $K < N$ ）的线性组合来表示。

$$\hat{x} = b_1 u_1 + b_2 u_2 + \dots + b_K u_K$$

其系数表示为： $\begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_K \end{bmatrix}$ 。

目标： 在降维中，我们的目标是找到一组最佳的 K 维基 u_i ，使得 $\hat{x}$ 尽可能地接近原始向量 $\underline{x}$ 。

示例：基变换

这一页通过一个 $K = N$ （即没有降维）的例子来展示**基变换**的概念，强调向量表示是相对基而言的。

- **情况 $K = N$ ：** 如果降维后的维度 K 等于原始维度 N ，那么近似向量 $\hat{x}$ 就等于原始向量 x ($\hat{x} = x$)。
- **示例：** 向量 x 在两个不同的 3 维基下的表示是不同的，但它们代表同一个向量。

- 标准基 v : $v_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, v_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, v_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$ 12。

$$\begin{matrix} 3 \\ x_v = \begin{bmatrix} 3 \end{bmatrix} = 3v_1 + 3v_2 + 3v_3 \text{ [cite: 193]} \\ 3 \end{matrix}$$

- 另一组基 u : $u_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, u_2 = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, u_3 = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$ 。

$$x_u = \begin{bmatrix} 3 \\ 3 \\ 3 \end{bmatrix} = 0u_1 + 0u_2 + 3u_3$$

- 虽然表示系数 $(3, 3, 3)$ 和 $(0, 0, 3)$ 不同，但向量本身是相同的 $(x_v = x_u)$ 。

这个例子为下一部分要讲解的 PCA 奠定了基础，即 PCA 的目标就是找到一个最“高效”的基（主成分），使得在低维空间中保留最多的信息。

PCA

主成分分析的目标与动机

目标

- 每个降维技术都会根据特定标准（例如信息损失、数据区分度等）来找到一个合适的变换。
- **PCA 的目标**是减少数据的维度，同时尽可能多地保留数据集中存在的**变异 (Variation)**，即方差。

动机和几何解释

PCA 的核心思想是找到一个能最大限度描述数据分散程度（方差）的方向。

- **高方差原则**：找到数据中具有**高方差**的基（方向）。
- **第一个主成分 (First PC)**：是数据中**最大方差**的方向。
- **后续主成分 (Subsequent PCs)**：与第一个主成分**正交**，并描述**最大残余方差**的方向。
- **编码**：使用少量基向量（主成分）来编码数据，以达到**低均方误差 (low MSE)** 的效果。

在第 20 页的图示中：

- x_1 和 x_2 是原始坐标轴。
- z_1 是第一个主成分方向（方差最大）。
- z_2 是第二个主成分方向，它与 z_1 正交（方差次大）。

PCA 的数学原理

PCA 的数学目标是找到一个方向向量 q ，使得数据投影到该方向上的方差最大化。

方差最大化

假设数据的均值 $E[x] = 0$ 。将数据向量 x 投影到单位向量 q 上的值记为 a ：

$$a = x^T q = q^T x$$

投影值 a 的方差 $(\sigma)^2$ 为：

$$(\sigma)^2 = E[a^2] - E[a]^2$$

由于 $E[a] = E[q^T x] = q^T E[x] = 0$ ，方差简化为：

$$(\sigma)^2 = E[a^2]$$

将其展开，并利用协方差矩阵 $R = E[xx^T]$ ：

$$(\sigma)^2 = E[(q^T x)(x^T q)] = q^T E[xx^T] q = q^T R q$$

其中 R 是数据的协方差矩阵。我们需要找到使 $q^T R q$ 最大化的单位向量 q ，且 q 必须是单位向量 ($\|q\| = (q^T q)^{1/2} = 1$)。

通过特征分解求解

可以证明，最大化方差的 q 正是协方差矩阵 R 的**主成分**（即特征向量）。

主成分 q_j 可以通过对协方差矩阵 R 进行特征向量分解 (Eigenvector Decomposition) 来获得：

$$R = Q \Lambda Q^T$$


其中：

- Q 是由特征向量 $q_1, q_2, \dots, q_m$ 组成的矩阵。
- Λ 是由特征值 $\lambda_1, \lambda_2, \dots, \lambda_m$ 组成的对角矩阵。
- **主成分 q_j 是矩阵 R 的特征向量**，满足 $Rq_j = \lambda_j q_j$ 。
- **方差与特征值：** 矩阵 R 的特征值 λ_j 对应于沿其特征向量 q_j 方向的数据方差。因此，按特征值大小排序，前 K 个特征向量就是方差最大的 K 个方向，即**主成分**。


PCA 的几何表示

第 22 页和第 23 页以散点图为例，展示了主成分与原始数据点的关系。

- 红色箭头代表**第一主成分 y_1** （方差最大的方向）；青色箭头代表**第二主成分 y_2** （与 y_1 正交，方差次大的方向）。



- 展示了原始数据点 (x_{i1}, x_{i2}) 如何投影到主成分轴上，得到降维后的坐标 (y_{i1}, y_{i2}) 。



- x_{i1}, x_{i2} : 原始坐标轴上的分量。
- $y_{i,1}, y_{i,2}$: 数据点在主成分轴上的投影值。
- **降维的意义**: 如果我们只保留 y_1 轴 (即第一个主成分), 就实现了从 2 维到 1 维的降维, 同时保留了大部分的方差信息。

PCA 的优缺点

优点 (Advantage)

- **维度降低**: 减少原始数据的维度。
 - 提高效率: 减少训练过程中的时间消耗, 提高效率。
- **去噪**: 舍弃原始数据的部分信息。
 - 如果舍弃的信息是**噪声 (noise)**, 则有助于数据清洗。

局限性/缺点 (Limitation5)

- **信息损失**: 舍弃原始数据的部分信息。
 - 如果舍弃的信息是**重要的**, 则不适合应用 PCA。
- **难解释性**: 主成分 (PC 或基) 可能**难以解释** (缺乏物理或语义意义)。

- **线性模型：** PCA 是一个**线性模型**。
 - 不适用于**非线性问题**（例如，数据分布在一个弯曲的流形上）。
- **重要性假设：** 假设第一个主成分具有更高的重要性（方差最大就是信息最重要的）。

案例研究：特征脸 (Eigenface)

- **应用领域：** 人脸识别。
- **原理：** 将每个脸部图像视为一个**高维向量**。
- **分解：** 通过对人脸图像数据集的协方差矩阵进行 PCA 分析，得到的**特征向量**可以被视为图像。这些特征向量被称为**特征脸 (Eigenfaces)**。
- **表示：** 任意一张人脸图像可以近似表示为**特征脸**（特征向量 b_i ）的**线性组合**。
 - 在图示中，原始人脸图像由平均脸加上四个特征脸 b_1, b_2, b_3, b_4 的线性组合（带有不同的权重系数）构成